

Tech Challenge — Fase 1

Predição de Câncer de Mama
(Wisconsin Diagnostic)

Repositório Git

https://github.com/lucianoft/machine_learning_cancer_mama

Machine Learning | API REST | Docker | Saúde da Mulher

Entregáveis incluídos

Código-fonte completo • README.md • Dockerfile
Dataset • Gráficos e métricas • Relatório técnico

Mapa dos entregáveis — Fase 1

Item	Descrição
Repositório Git	https://github.com/lucianoft/machine_learning_cancer_mama
Código-fonte	api/, models/, Tech_Challenge_Breast_Cancer.ipynb
README	Instruções de notebook, Docker e API
Docker	Dockerfile + docker-compose.yml
Dataset	breast_cancer_wisconsin.csv (569 amostras)
Resultados	Gráficos, métricas e exemplos de API neste PDF
Relatório	Seções 1 a 4 — EDA, pré-processamento, modelos e resultados

Métricas principais (conjunto de teste)

Modelo	
Logistic Regression	96,4%
Random Forest	92,8%
K-Nearest Neighbors	96,6%
Decision Tree	88,4%

Modelo selecionado para produção: Logistic Regression (maior F1-Score).

Relatório Técnico

****Projeto:** Sistema de apoio à decisão clínica com Machine Learning**

Repositório Git: https://github.com/lucianoft/machine_learning_cancer_mama

Dataset: breast_cancer_wisconsin.csv (incluso no repositório)

Download alternativo: Kaggle - Breast Cancer Wisconsin | UCI ML Repository

Variável alvo: diagnosis (0 = benigno, 1 = maligno)

Notebook: Tech_Challenge_Breast_Cancer.ipynb

1. Discussões da Análise Exploratória

1.1 Contexto do problema

O conjunto foi curado por Wolberg, Street e Mangasarian (University of Wisconsin) e está disponível no repositório UCI. É um benchmark clássico em classificação médica e saúde da mulher — tema central do Tech Challenge.

A variável alvo é diagnosis: B (benigno) ou M (maligno), codificada como 0 e 1 no pipeline.

1.2 Dimensão e balanceamento

| Aspecto | Valor |

|-----|-----|

| Registros | 569 |

| Atributos | 32 colunas (id + diagnosis + 30 features) |

| Benigno (0) | 357 (62,7%) |

Maligno (1)	212 (37,3%)
O dataset é **moderadamente balanceado** em	

1.3 Valores ausentes

Nenhum valor ausente no dataset diagnostic. Não foi necessária imputação agressiva; o SimpleImputer no pipeline permanece por consistência e robustez em produção.

1.4 Variáveis relevantes

As 30 features derivam de 10 medidas de núcleos celulares:

- Geométricas: raio, perímetro, área
- Textura: desvio padrão de tons de cinza
- Forma: suavidade, compacidade, concavidade, pontos côncavos, simetria, dimensão fractal

Cada medida aparece em três versões: mean (média), error (erro padrão) e worst (média dos três maiores valores).

1.5 Correlação

A matriz de correlação mostra forte associação entre raio, perímetro e área — esperado por definição geométrica. Features `worst_*` tendem a correlacionar fortemente com o diagnóstico maligno.

1.6 Conclusões da EDA

- Dataset adequado ao desafio de classificação em saúde feminina.
- Balanceamento razoável permite usar accuracy, recall e F1 de forma complementar.
- Features derivadas diretamente da amostra citológica — contexto de apoio ao diagnóstico pós-PAAF, não triagem populacional por questionário.
- ---

2. Estratégias de Pré-processamento

2.1 Seleção de features (30 colunas)

| Excluída | Motivo |

|-----|-----|

| id | Identificador da amostra |

| diagnosis | Variável alvo |

2.2 Pipeline sklearn

```
SimpleImputer(median) → StandardScaler → Classificador  
...
```

Encapsulado em `ColumnTransformer` + `Pipeline` para uso idêntico no treino e na API REST.

2.3 Divisão dos dados

- 80% treino (455) / 20% teste (114)
- Estratificação por diagnosis
- `random_state=42`

2.4 Balanceamento

`class_weight='balanced'` em Regressão Logística, Árvore e Random Forest.

3. Modelos Usados e Porquê

| Modelo | Justificativa |

|-----|-----|

| Regressão Logística | Baseline interpretável; excelente em dados linearmente separáveis |

| Árvore de Decisão | Captura regras não lineares entre medidas morfológicas |

| Random Forest | Ensemble robusto; referência em benchmarks tabulares |

KNN	Compara amostras similares; referência do notebook de ML avançado
Critério de seleção para deploy: **maior F1-Score**	

4. Resultados e Interpretação dos Dados

4.1 Métricas comparativas (teste — 114 amostras)

Modelo Accuracy Recall F1-Score
----- ----- ----- -----
Logistic Regression 97,4% 95,2% 96,4%
Random Forest 97,4% 92,9% 96,3%
K-Nearest Neighbors 95,6% 90,5% 93,8%
Decision Tree 90,4% 83,3% 86,4%

4.2 Regressão Logística — detalhamento

precision	recall	f1-score	support	
Benigno	0.97	0.99	0.98	72
Maligno	0.98	0.95	0.96	42
accuracy			0.97	114

4.3 Interpretação

- Regressão Logística apresenta melhor F1-Score (96,4%) e foi salva como pipeline final para REST.
- Recall de 95,2% para malignos — poucos falsos negativos, crítico em contexto oncológico.
- Métricas altas refletem que as features são extraídas do mesmo material citológico usado no diagnóstico — problema bem definido e com forte sinal preditivo.
- Falsos negativos (maligno classificado como benigno) permanecem o erro mais grave clinicamente.

4.4 Uso prático

- Apoio à decisão em análise de PAAF — segunda opinião automatizada.
- API REST — pipeline em models/pipeline_breast_cancer.pkl.
- Integração com sistemas de patologia digital (mediante extração das 30 medidas).

4.5 Limitações

- Amostra de 569 casos de uma única origem (Wisconsin, anos 1990).
- Features exigem imagem digitalizada de PAAF — não aplicável a triagem só com dados demográficos.
- Não substitui avaliação médica, mamografia nem biópsia definitiva.
- O profissional de saúde tem a palavra final.

4.6 Conclusão

O projeto atende ao Tech Challenge com classificação em saúde feminina, EDA documentada, pipeline reprodutível e modelo serializado para REST. O dataset Wisconsin oferece base mais estável que problemas fortemente desbalanceados por questionário, com métricas adequadas para demonstração e deploy.

Referências

- UCI ML Repository: [Breast Cancer Wisconsin (Diagnostic)](<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>)
- Kaggle: [Breast Cancer Wisconsin (Diagnostic)](<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>)
- Tech Challenge IADT — Fase 1 (‘IADT - Fase 1 - Tech challenge A.pdf’)




Figura 1 — Distribuição da variável alvo (benigno vs maligno)




Figura 2 — Histogramas das variáveis numéricas




Figura 3 — Pairplot das medidas mean_* por diagnóstico




Figura 4 — Matriz de correlação entre features




Figura 5 — Matriz de confusão (Regressão Logística)




Figura 6 — Comparação de modelos por F1-Score

API REST — Resultados

API FastAPI containerizada com Docker. A pipeline treinada no notebook é carregada automaticamente na inicialização.

Método	Rota	Descrição
GET	/health	Status da API
GET	/metadata	Metadados do modelo
POST	/predict	Classificação benigno/maligno

Exemplo — GET /health

```
{
  "status": "ok",
  "model_name": "Logistic Regression"
}
```

Exemplo — POST /predict

Request: api/example_request.json (30 medidas de núcleos celulares)

```
{
  "predicao": 0,
  "label": "Benigno",
  "probabilidade_benigno": 0.9092,
  "probabilidade_maligno": 0.0908
}
```

Deploy

Modelo: Logistic Regression
Arquivo: models/pipeline_breast_cancer.pkl
Comando: docker compose up --build
Docs: <http://localhost:8000/docs>