

Tech Challenge IADT — Fase 1

Predição de Câncer de Mama (Wisconsin Diagnostic)

Repositório Git:

https://github.com/lucianoft/machine_learning_cancer_mama

Entregáveis: código-fonte, README, Dockerfile, dataset,
resultados (gráficos e métricas) e relatório técnico.

Mapa dos entregáveis — Fase 1

Repositório Git: https://github.com/lucianoft/machine_learning_cancer_mama

Código-fonte: `api/`, `models/`, `Tech_Challenge_Breast_Cancer.ipynb`

README: `README.md` (instruções notebook + Docker)

Docker: `Dockerfile` e `docker-compose.yml`

Dataset: `breast_cancer_wisconsin.csv` (repositório)

Links: Kaggle e UCI (ver relatório)

Resultados: gráficos e métricas neste PDF + notebook

Relatório técnico: seções 1 a 4 abaixo

Relatório Técnico

Predição de Câncer de Mama (Wisconsin Diagnostic)

Projeto: Sistema de apoio à decisão clínica com Machine Learning

Repositório Git: https://github.com/lucianoft/machine_learning_cancer_mama

Dataset: breast_cancer_wisconsin.csv (incluso no repositório)

Download alternativo: Kaggle - Breast Cancer Wisconsin | UCI ML Repository

Variável alvo: diagnosis (0 = benigno, 1 = maligno)

Notebook: Tech_Challenge_Breast_Cancer.ipynb

1. Discussões da Análise Exploratória

1.1 Contexto do problema

O conjunto foi curado por Wolberg, Street e Mangasarian (University of Wisconsin) e está disponível no repositório UCI. É um benchmark clássico em classificação médica e saúde da mulher — tema central do Tech Challenge.

A variável alvo é diagnosis: B (benigno) ou M (maligno), codificada como 0 e 1 no pipeline.

1.2 Dimensão e balanceamento

Aspecto | Valor

Registros | 569

Atributos | 32 colunas (id + diagnosis + 30 features)

Benigno (0) | 357 (62,7%)

Maligno (1) | 212 (37,3%)

O dataset é moderadamente balanceado em comparação com problemas de triagem por questionário, o que permite métricas mais estáveis (recall, F1 e accuracy).

1.3 Valores ausentes

Nenhum valor ausente no dataset diagnostic. Não foi necessária imputação agressiva; o SimpleImputer no pipeline permanece por consistência e robustez em produção.

1.4 Variáveis relevantes

As 30 features derivam de 10 medidas de núcleos celulares:

- Geométricas: raio, perímetro, área
- Textura: desvio padrão de tons de cinza
- Forma: suavidade, compacidade, concavidade, pontos côncavos, simetria, dimensão fractal

Cada medida aparece em três versões: mean (média), error (erro padrão) e worst (média dos três maiores valores).

1.5 Correlação

A matriz de correlação mostra forte associação entre raio, perímetro e área — esperado por definição geométrica. Features worst_* tendem a correlacionar fortemente com o diagnóstico maligno.

1.6 Conclusões da EDA

1. Dataset adequado ao desafio de classificação em saúde feminina.
2. Balanceamento razoável permite usar accuracy, recall e F1 de forma complementar.

3. Features derivadas diretamente da amostra citológica — contexto de apoio ao diagnóstico pós-PAAF, não triagem populacional por questionário.

2. Estratégias de Pré-processamento

2.1 Seleção de features (30 colunas)

Excluída | Motivo
id | Identificador da amostra
diagnosis | Variável alvo

2.2 Pipeline sklearn

``
SimpleImputer(median) → StandardScaler → Classificador
`

Encapsulado em ColumnTransformer + Pipeline` para uso idêntico no treino e na API REST.

2.3 Divisão dos dados

- 80% treino (455) / 20% teste (114)
- Estratificação por diagnosis
- random_state=42

2.4 Balanceamento

class_weight='balanced' em Regressão Logística, Árvore e Random Forest.

3. Modelos Usados e Porquê

Modelo | Justificativa
Regressão Logística | Baseline interpretável; excelente em dados linearmente separáveis
Árvore de Decisão | Captura regras não lineares entre medidas morfológicas
Random Forest | Ensemble robusto; referência em benchmarks tabulares
KNN | Compara amostras similares; referência do notebook de ML avançado

Critério de seleção para deploy: maior F1-Score no teste.

4. Resultados e Interpretação dos Dados

4.1 Métricas comparativas (teste — 114 amostras)

Modelo | Accuracy | Recall | F1-Score
Logistic Regression | 97,4% | 95,2% | 96,4%
Random Forest | 97,4% | 92,9% | 96,3%
K-Nearest Neighbors | 95,6% | 90,5% | 93,8%
Decision Tree | 90,4% | 83,3% | 86,4%

4.2 Regressão Logística — detalhamento

``

	precision	recall	f1-score	support
Benigno	0.97	0.99	0.98	72

Maligno	0.98	0.95	0.96	42
accuracy		0.97	114	

4.3 Interpretação

- Regressão Logística apresenta melhor F1-Score (96,4%) e foi salva como pipeline final para REST.
- Recall de 95,2% para malignos — poucos falsos negativos, crítico em contexto oncológico.
- Métricas altas refletem que as features são extraídas do mesmo material citológico usado no diagnóstico — problema bem definido e com forte sinal preditivo.
- Falsos negativos (maligno classificado como benigno) permanecem o erro mais grave clinicamente.

4.4 Uso prático

1. Apoio à decisão em análise de PAAF — segunda opinião automatizada.
2. API REST — pipeline em models/pipeline_breast_cancer.pkl.
3. Integração com sistemas de patologia digital (mediante extração das 30 medidas).

4.5 Limitações

- Amostra de 569 casos de uma única origem (Wisconsin, anos 1990).
- Features exigem imagem digitalizada de PAAF — não aplicável a triagem só com dados demográficos.
- Não substitui avaliação médica, mamografia nem biópsia definitiva.
- O profissional de saúde tem a palavra final.

4.6 Conclusão


O projeto atende ao Tech Challenge com classificação em saúde feminina, EDA documentada, pipeline reprodutível e modelo serializado para REST. O dataset Wisconsin oferece base mais estável que problemas fortemente desbalanceados por questionário, com métricas adequadas para demonstração e deploy.

Referências

- UCI ML Repository: Breast Cancer Wisconsin (Diagnostic)
- Kaggle: Breast Cancer Wisconsin (Diagnostic)
- Tech Challenge IADT — Fase 1 (IADT - Fase 1 - Tech challenge A.pdf)


Resultados visuais — Notebook

Gráficos gerados pela execução de Tech_Challenge_Breast_Cancer.ipynb (análise exploratória, matriz de confusão e comparação de modelos).




Distribuição da variável alvo (diagnosis: benigno vs maligno)

Distribuição de todas as variáveis numéricas




Histogramas das variáveis numéricas do dataset




Pairplot das 10 medidas mean_ (colorido por diagnóstico)*

Matriz de correlacao




Matriz de correlação entre as features

Matriz de Confusao - Regressao Logistica



Matriz de confusão — Regressão Logística



Comparação de modelos por F1-Score

API REST — Resultados

API FastAPI em Docker. Documentação interativa: <http://localhost:8000/docs>

Collection Postman: [postman/Tech_Challenge_Breast_Cancer.postman_collection.json](#)

Endpoints

GET /health — Status da API e modelo carregado

GET /metadata — Metadados, features e variável alvo

POST /predict — Classificação benigno/maligno (30 features)

Exemplo GET /health

```
{
  "status": "ok",
  "model_name": "Logistic Regression"
}
```

Exemplo POST /predict (amostra benigna)

Request: [api/example_request.json](#) (30 medidas de núcleos celulares)

Response:

```
{
  "predicao": 0,
  "label": "Benigno",
  "probabilidade_benigno": 0.9092,
  "probabilidade_maligno": 0.0908
}
```

Modelo em produção: Logistic Regression

Pipeline serializada: [models/pipeline_breast_cancer.pkl](#)

Execução

`docker compose up --build`

`curl -X POST http://localhost:8000/predict -H "Content-Type: application/json" -d @api/example_request.json`